

模式识别课后作业一

2020E8013282019 李一帆

October 7, 2020

1 问题 1

由题目可知，类别 ω_j 判断为 α_i 的决策代价可以表示为：

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0, & i = j \\ \lambda_s, & i \neq j \\ \lambda_r, & \text{reject} \end{cases}$$

条件风险 $R(\alpha_i|x)$ 可以表示为：

$$R(\alpha_i|x) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|x)$$

通过推导可知条件风险 $R_i(x)$ 可以表示为：

$$R_i(x) = \begin{cases} \sum_{j \neq i}^c \lambda(\alpha_i|\omega_j)P(\omega_j|x) = \lambda_s[1 - P(\omega_i|x)], & i = 1, \dots, c \\ \lambda_r, & \text{reject} \end{cases}$$

因为在 $i = 1, 2, \dots, c$ 情况下，如果对应的条件风险更小，则不会被拒绝，反之则被拒绝，即 $\lambda_s(1 - P(\omega_i|x)) < \lambda_r \Rightarrow P(\omega_i|x) > 1 - \lambda_r/\lambda_s$ 。根据条件风险最小化原则，有如下公式成立：

$$\arg \min_i R_i(x) = \begin{cases} \arg \max_i P(\omega_i|x), & \text{if } \max_i P(\omega_i|x) > 1 - \lambda_r/\lambda_s \\ \text{reject}, & \text{otherwise} \end{cases}$$

当 $\lambda_r = 0$ 时，有 $\max_i P(\omega_i|x) < 1$ ，第一个条件恒不成立，因此被拒绝。

当 $\lambda_r > \lambda_s$ 时，有 $1 - \lambda_r/\lambda_s < 0 \Rightarrow \max_i P(\omega_i|x) > 1 - \lambda_r/\lambda_s$ ，即第一个条件恒成立，因此拒绝的条件会被无效化，起不到拒绝的效果。

2 问题 2




Figure 1: 错误率.

2.1 第 1 小问

由 Figure 1 所示，当决策边界位于两概率密度函数的交点处时，即 $\frac{\mu_1 + \mu_2}{2}$ ，误差概率最小（reducible error=0）。根据定义，此刻的最小误差概率 P_e 为对阴影部分的积分，推导过程如下所示。

$$\begin{aligned}
 P_e &= P(x \in R_2, \omega_1) + P(x \in R_1, \omega_2) \\
 &= P(x \in R_2 | \omega_1)P(\omega_1) + P(x \in R_1 | \omega_2)P(\omega_2) \\
 &= \frac{1}{2} \left(\int_{R_2} P(x \in R_2 | \omega_1) dx + \int_{R_1} P(x \in R_1 | \omega_2) dx \right) \\
 &= \frac{1}{2} \cdot 2 \int_{R_2} P(x \in R_2 | \omega_1) dx \\
 &= \int_{\frac{\mu_1 + \mu_2}{2}}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x - \mu_1)^2}{2\sigma^2}} dx \\
 &= \sigma \int_{\frac{\mu_1 + \mu_2}{2}}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left(\frac{x - \mu_1}{\sigma} \right)^2} d\left(\frac{x - \mu_1}{\sigma} \right) \\
 &= \frac{1}{\sqrt{2\pi}} \int_{\frac{\mu_2 - \mu_1}{2\sigma}}^{+\infty} e^{-\frac{1}{2}\mu^2} d\mu
 \end{aligned}$$

其中，由于 $\mu_2 > \mu_1$ ，所以积分下限 $\frac{\mu_2 - \mu_1}{2}$ 应写为 $\frac{|\mu_1 - \mu_2|}{2}$ 。

2.2 第 2 小问

由第 1 小问可知, $P_e \geq \frac{1}{\sqrt{2\pi}} \int_{\frac{|\mu_2 - \mu_1|}{2\sigma}}^{+\infty} e^{-\frac{1}{2}\mu^2} d\mu$, 因此, 结合第 2 小问所给出信息有如下不等式成立。

$$\frac{1}{\sqrt{2\pi}} \int_a^{+\infty} e^{-\frac{1}{2}\mu^2} d\mu \leq P_e \leq \frac{1}{\sqrt{2\pi}a} e^{-\frac{1}{2}a^2}$$

其中, $a = \frac{|\mu_2 - \mu_1|}{2\sigma}$ 。因为有如下极限成立:

$$\lim_{a \rightarrow +\infty} \frac{1}{\sqrt{2\pi}} \int_a^{+\infty} e^{-\frac{1}{2}\mu^2} d\mu = \lim_{a \rightarrow +\infty} [1 - \Phi(a)] = 0$$

$$\lim_{a \rightarrow +\infty} \frac{1}{\sqrt{2\pi}a} e^{-\frac{1}{2}a^2} = 0$$

因此, 根据夹逼准则可知, $\lim_{a \rightarrow +\infty} P_e = 0$ 。

3 问题 3

3.1 第 1 小问

条件概率密度 $P(\mathbf{x}|\omega_i)$ 可以表示为如下形式。

$$P(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) \right]$$

3.2 第 2 小问

(a) 在类协方差矩阵 Σ_i 不等的情况下, 最小误差判别函数 $g_i(\mathbf{x})$ 可以表示为

$$g_i(\mathbf{x}) = -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

(b) 在类协方差矩阵相等的情况下, 可以细分为两种情况。

Case 1: $\Sigma_i = \sigma^2 \mathbf{I}$, 此时的最小误差判别函数 $g_i(\mathbf{x})$ 可以表示为如下形式。

$$g_i(\mathbf{x}) = -\frac{\|\mathbf{x} - \mu_i\|^2}{2\sigma^2} + \ln P(\omega_i)$$

Case 2: $\Sigma_i = \Sigma$, 此时最小误差判别函数 $g_i(\mathbf{x})$ 可以表示为如下形式。

$$g_i(\mathbf{x}) = -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma^{-1} (\mathbf{x} - \mu_i) + \ln P(\omega_i)$$

3.3 第 3 小问

方法 1: 利用 PCA 对协方差矩阵进行降维处理。

方法 2: 在协方差矩阵的基础上加上一个 $\varepsilon \mathbf{I}$, 其中, ε 足够小。

4 问题 4

在高斯分布协方差矩阵相同的情况下，决策面与坐标轴的交点 x_0 可以表示为如下方程。

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\ln [P(\omega_i)/P(\omega_j)]}{(\mu_i - \mu_j)^t \Sigma^{-1}(\mu_i - \mu_j)}(\mu_i - \mu_j)$$

如果先验概率相等，决策面经过两均值向量的中点处。如果不等，则边界会移向先验概率较小的均值，如果两先验概率之差足够大，判定面可以不落在两均值向量之间。

5 问题 5

5.1 第 1 小问

在 $z_{ik} = 1$ 的情况下，第 k 个样本的类别为 ω_i ，先验概率为 $P(\omega_i)$ 。

$$P(\omega_i)^{z_{ik}} \cdot (1 - P(\omega_i))^{1-z_{ik}} = P(\omega_i)$$

在 $z_{ik} = 0$ 的情况下，第 k 个样本的类别不为 ω_i ，先验概率为 $1 - P(\omega_i)$ 。

$$P(\omega_i)^{z_{ik}} \cdot (1 - P(\omega_i))^{1-z_{ik}} = 1 - P(\omega_i)$$

当 z_{ik} 为不确定值时，第 k 个样本类别不确定，对应的先验概率可以合并为 $P(\omega_i)^{z_{ik}}(1 - P(\omega_i))$ 。又根据独立性原则，最终的似然可以表示为如下形式。

$$P(z_{ik}, \dots, z_{in} | P(\omega_i)) = \prod_{k=1}^n P(\omega_i)^{z_{ik}} (1 - P(\omega_i))^{1-z_{ik}}$$

5.2 第 2 小问

将似然 $P(z_{ik}, \dots, z_{in} | P(\omega_i))$ 取对数后得 $l(P(\omega_i))$ 。

$$l(P(\omega_i)) = \sum_{k=1}^n [z_{ik} \ln P(\omega_i) + (1 - z_{ik}) \ln(1 - P(\omega_i))]$$

将取对数后的似然对先验 $P(\omega_i)$ 进行求导运算，如下所示。

$$\nabla_{P(\omega_i)} l = \sum_{k=1}^n \left[\frac{z_{ik}}{P(\omega_i)} + \frac{z_{ik} - 1}{1 - P(\omega_i)} \right] = \sum_{k=1}^n \frac{z_{ik} - P(\omega_i)}{P(\omega_i)(1 - P(\omega_i))}$$

令导数为 0 可以求得对先验 $P(\omega_i)$ 的最大似然估计。

$$\nabla_{P(\omega_i)} l = 0 \Rightarrow \sum_{k=1}^n z_{ik} - nP(\omega_i) = 0 \Rightarrow \hat{P}(\omega_i) = \frac{1}{n} \sum_{k=1}^n z_{ik}$$

6 问题 6

6.1 第 1 小问

(a) 将均值的迭代公式进行展开，如下所示。

$$\begin{aligned}
 \hat{\mu}_{n+1} &= \hat{\mu}_n + \frac{1}{n+1}(x_{n+1} - \hat{\mu}_n) = \frac{n}{n+1}\hat{\mu}_n + \frac{1}{n+1}x_{n+1} = \frac{n}{n+1} \cdot \left(\frac{n-1}{n}\hat{\mu}_{n-1} + \frac{1}{n}x_n\right) \\
 &= \frac{n}{n+1} \cdot \left(\frac{n-2}{n}\hat{\mu}_{n-2} + \frac{1}{n}x_{n-1} + \frac{1}{n}x_n\right) + \frac{1}{n+1}x_{n+1} \\
 &= \frac{n-2}{n+1}\hat{\mu}_{n-2} + \frac{1}{n+1}(x_{n-1} + x_n + x_{n+1}) \\
 &= \cdots = \frac{1}{n+1}\hat{\mu}_1 + \frac{1}{n+1}(x_2 + \cdots + x_n + x_{n+1}) \\
 &= \frac{1}{n+1}(x_1 + x_2 + \cdots + x_n + x_{n+1}) = \frac{1}{n+1} \sum_{k=1}^{n+1} x_k
 \end{aligned}$$

因此， $\hat{\mu}_n = \frac{1}{n} \sum_{k=1}^n x_k$ 成立。

(b) 将上面得到的均值迭代公式代入到方差计算公式中可以有如下推导。

$$\begin{aligned}
 C_{n+1} &= \frac{1}{n} \sum_{i=1}^{n+1} \left[x_i - \left(\mu_n + \frac{x_{n+1} - \mu_n}{n+1} \right) \right] \left[x_i - \left(\mu_n + \frac{x_{n+1} - \mu_n}{n+1} \right) \right]^t \\
 &= \frac{1}{n} \sum_{i=1}^{n+1} \left[(x_i - \mu_n) - \left(\frac{x_{n+1} - \mu_n}{n+1} \right) \right] \left[(x_i - \mu_n) - \left(\frac{x_{n+1} - \mu_n}{n+1} \right) \right]^t \\
 &= \frac{1}{n} \sum_{i=1}^{n+1} \left[(x_i - \mu_n)(x_i - \mu_n)^t - 2(x_i - \mu_n) \left(\frac{x_{n+1} - \mu_n}{n+1} \right)^t + \left(\frac{x_{n+1} - \mu_n}{n+1} \right) \left(\frac{x_{n+1} - \mu_n}{n+1} \right)^t \right] \\
 &= \frac{n+1}{n} \left(\frac{x_{n+1} - \mu_n}{n+1} \right) \left(\frac{x_{n+1} - \mu_n}{n+1} \right)^t + \frac{1}{n} \sum_{i=1}^{n+1} \left[(x_i - \mu_n)(x_i - \mu_n)^t - 2(x_i - \mu_n) \left(\frac{x_{n+1} - \mu_n}{n+1} \right)^t \right] \\
 &= \frac{1}{n(n+1)} (x_{n+1} - \mu_n)(x_{n+1} - \mu_n)^t + \frac{1}{n} \left[(x_{n+1} - \mu_n)(x_{n+1} - \mu_n)^t - 2 \frac{(x_{n+1} - \mu_n)(x_{n+1} - \mu_n)^t}{n+1} \right] \\
 &\quad + \frac{1}{n} \sum_{i=1}^n \left[(x_i - \mu_n)(x_i - \mu_n)^t - 2 \frac{(x_i - \mu_n)(x_{n+1} - \mu_n)^t}{n+1} \right] \\
 &= \left(\frac{1}{n(n+1)} + \frac{1}{n} \cdot \frac{n-1}{n+1} \right) (x_{n+1} - \mu_n)(x_{n+1} - \mu_n)^t + \frac{1}{n} \sum_{i=1}^n (x_i - \mu_n)(x_i - \mu_n)^t \\
 &\quad - 2 \frac{x_{n+1} - \mu_n}{n(n+1)} \sum_{i=1}^n (x_i - \mu_n) \\
 &= \frac{1}{n+1} (x_{n+1} - \mu_n)(x_{n+1} - \mu_n)^t + \frac{1}{n} \sum_{i=1}^n (x_i - \mu_n)(x_i - \mu_n)^t \\
 &= \frac{1}{n+1} (x_{n+1} - \mu_n)(x_{n+1} - \mu_n)^t + \frac{n-1}{n} \cdot \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu_n)(x_i - \mu_n)^t \\
 &= \frac{1}{n+1} (x_{n+1} - \mu_n)(x_{n+1} - \mu_n)^t + \frac{n-1}{n} C_n
 \end{aligned}$$

6.2 第 2 小问

计算均值迭代每一步需要 d 次运算，迭代 n 次则需要 nd 次运算；计算方差迭代每一步计算 $x_{n+1} - m_n$ 需要 d 次运算，计算 $(x_{n+1} - m_n)(x_{n+1} - m_n)^t$ 需要 d^2 次运算，因此每一步需要 d^2 次运算，迭代 n 次则需要 nd^2 次运算。